

面向 LLM 社会模拟的科学性纪律： 以独居老人社会支持干预为案例的分层生成式智能体模拟

惠栋帅 王才厚 雷明仁

AISS 2026 挑战赛参赛论文

摘要

多智能体 LLM 社会模拟面临三重质疑：数据是否凭空捏造、结论是否可复现、发现是否只是规则的回声。本文以独居老人社会支持干预为案例，提出并演示一套面向 LLM 社会模拟的**科学性纪律**：预注册假设与效度门槛、真实调查数据锚定、失效 run 归档与根因分类、含沉没成本的成本核算，以及**“规定 vs 涌现”的逐条对照**。模拟基于 AgentSociety2：6 名 LLM 驱动的焦点老人嵌入 20 人规则层支持网络，1 步 = 1 月、共 24 月，比较专业社工个案管理（casework）、时间银行互助（timebank）与数字平台志愿匹配（platform）于第 7-18 月实施、其后撤出 6 个月。结果（11/12 有效 run）：干预期个案管理孤立率最低（7.9% 对基线 29.4%），撤出后反弹 +19.6pp；时间银行反弹 +0.8pp。我们如实说明：这一可持续性分化是在显式编码的机制假设（干预即时接触、结对延续概率）下复现的预期形态，而非涌现发现；分层拆解显示宏观孤立率的 58% 来自 LLM 层，且时间银行的“不反弹”主要由规则层贡献，LLM 层仍反弹 +12.0pp。真正的涌现结果在行为层：三种干预的求助行为签名可区分，个案管理组求助最多、成功率最低；跨模型检验发现 gpt-6-astra 在无干预时更倾向“不行动”、外部行动者来访会拉动其产出决策，这对 LLM 社会模拟的效度门槛设计具有一般含义。所有结果可由公开脚本一键复现。

关键词：生成式智能体；社会支持网络；独居老人；社会工作干预；时间银行；多智能体模拟

1 引言

本文的主要贡献有三：

中国 65 岁以上独居老人的孤独与社会隔离问题规模庞大：CLHLS 2008/09 波数据显示独居老人“感到孤独”比例达 52%，几乎两倍于非独居老人（29.5%）[1]（该数字为问题规模的背景引用；本文校准使用 2021 波独居子样本、“经常/总是”口径，两处波次与判定口径不同，不可直接比较）。社会工作实务发展出多种干预路径——专业社工个案管理、社区互助（时间银行）、数字平台志愿服务——但两个关键问题在实证文献中始终难以回答：

（一）**干预撤出之后会发生什么？**RCT 与准实验几乎都在项目期内或结束时测量结局[2]，撤出后的反事实轨迹在真实世界中无法观测：我们不能对同一批老人既实施又不实施干预。

（二）**何时介入最划算？**轮候与预算约束使启动时机成为真实的政策变量，但时机的边际代价从未被系统量化。

生成式智能体模拟[3]为此提供了新工具：LLM 驱动的智能体在可控环境中产生带理由的行为决策，同一随机种子下可以重放“平行世界”。然而多智能体 LLM 模拟面临三重质疑——数据是否凭空捏造、结论是否可复现、“发现”是否只是环境规则的回声。

1. **一套可迁移的科学性纪律**：预注册假设与效度门槛、真实调查数据逐维锚定、失效 run 归档与根因分类（基础设施型 vs 行为型）、含沉没成本的真实成本核算、以及**“规定 vs 涌现”对照表**——逐条标明哪些结果是环境规则的直接推论、哪些才是模拟给出的新信息（表 3）。
2. **分层混合架构及其分层拆解**：LLM 焦点层（6 老人）嵌入规则层（20 人网络），零 API 成本的规则层支撑大样本扫描；我们进一步从 trace 中拆出两层各自的孤立率轨迹，量化 LLM 层在宏观结果中的权重与两层行为差异（表 2）。
3. **关于 LLM 智能体作为社会模拟主体的两项行为层发现**：(i) 三种干预在焦点老人求助行为上留下可区分的签名，个案管理组求助最多而成功率最低；(ii) 跨模型检验显示 gpt-6-astra 在无干预时更倾向“不行动”，外部行动者来访会拉动其产出决策，提示效度门槛应与模型特征联合设计。

上述之外，撤出后可持续性分化（H4）与介入时机的延迟成本在本文中作为显式机制假设下复现的预

期形态及其灵敏度范围报告，不作为涌现发现。

2 相关工作与理论基础

社会支持理论与护航模型。护航模型 (convoy model) [4] 把老年人的社会关系视为随生命历程移动的分层护航队：内层（配偶、子女）稳定但受丧偶、健康冲击侵蚀，外层（邻里、朋友）流动性高。本模拟的关系账本直接操作化这一结构：每条关系有强度、类型与最近联系时间，无联系则衰减。

关系衰减的实证形态。Burt 的跨研究拟合表明关系衰减率非常数、呈幂函数，“越老的关系越稳”[5]；老年人关系终止亦有直接测量 [6]。我们在第 7 节以 Burt 口径实测本模型的存活曲线并如实报告结构性偏差。

孤独干预的效应证据。Masi 等的荟萃给出四类干预的效应标尺（社会认知类 $d = -0.598$ 最大）[7]；Hoang 等按亚型拆分显示技术类干预 CI 跨零、多组件干预在社区场景显著 [8]。个案管理的两个 RCT（独居老人 [9]、社区失能老人 [10]）方向一致但 ITT 均保守。时间银行的准实验证据表明效应至少维持到项目终点且无挤出 [2]。这些效应量与方向构成三种干预的参数依据与结果检验标尺。

生成式智能体模拟。Park 等确立了 LLM 智能体产生可信社会行为的范式 [3]。本文的差异在于：以政策比较为目的的预注册实验设计、真实调查数据校准、以及对模拟有效性的系统核查。

3 方法：分层混合模拟

3.1 总体架构

模拟基于 AgentSociety2 框架 (Ray 并行、全程 trace 留痕、决策可回放)。20 名独居老人构成支持网络；其中 6 名为 **LLM 焦点老人** (PersonAgent, 模型 gpt-5.6-sol)，每月经多轮工具循环感知环境、检索记忆、做出行动决策并输出自然语言理由；其余 14 名与全部网络动力学由规则层驱动（关系衰减、月度事件、干预机制），不消耗 LLM 调用。焦点层提供机制与叙事证据，规则层保证网络结构的完整性并支撑零成本的大样本敏感性扫描。实测调用密度约 13.8 次/焦点老人·月。**两层的接触生成机制不同**：规则层老人每月按子女联系频率与外向性自动产生联系；焦点老人的联系只来自其自身工

具行动（打电话、走访、求助、参加活动）与干预者的来访，LLM 一个月不行动即记为当月无接触。这一差异是第 5.3 节两层孤立率水平相差三倍的直接原因，也意味着焦点层孤立率同时度量“老人是否孤立”与“LLM 是否行动”。

3.2 环境与关系账本

环境模块 (ElderSupportEnv) 维护每位老人的关系账本：关系类型（子女/邻里/朋友/志愿者/社工）、强度 $s \in [0, 1]$ 、每月联系频率与最近联系月份。当月无任何联系的关系按 $s \leftarrow s \times (1 - \delta)$ 衰减（基准 $\delta = 0.06$ ，敏感性扫描 0.15/0.25）， $s < 0.05$ 即删除。月度事件包括健康冲击、丧偶（触发孤独感跃升，校准于 CHARLS +27pp 风险差与 CLHLS 丧偶动态 [11]）、子女探访等。孤独感 $\ell \in [0, 1]$ 由关系激活量与事件驱动； $\ell \geq 0.6$ 判为“孤独”（对应 CLHLS b38 “经常/总是”，基线靶标约 15%）。

3.3 三种干预

- **casework 专业社工个案管理**：风险评估排序后对高危老人探访并联结家庭，自上而下、精准但受个案量约束。参数依据 Masi 社会认知类效应 [7] 与两个个案管理 RCT [9, 10]；覆盖率上限 = 社工数 $\times$ caseload。
- **timebank 时间银行互助**：低龄健康老人结对高危老人、服务换积分，规则自动执行；结点是真实人际关系，撤出后以 post_persist（中点 0.5，扫描 0.3–0.7）概率延续。参数依据香港时间银行准实验 [2]，撤出后延续概率无文献点估计，故作扫描处理。
- **platform 数字平台志愿匹配**：响应式、覆盖广、志愿者轮换、关系浅。效应设为三者最弱，依据技术类干预 CI 跨零的荟萃结果 [8]。

3.4 数据校准

画像生成分布逐维锚定真实调查：性别（女 63.8%）、自评健康、孤独感基线五档、在世子女数、子女常探望比例（78.7%）取自 CLHLS 2021 独居子样本；子女距离取自 CHARLS 2015；纵向动态锚点（独居老人三年孤独发生率 27.2%、持续率 53.3%、丧

偶冲击 +27pp) 取自 Harmonized CHARLS 2011–2018。判定口径映射与已知偏差 (CLHLS 高龄过抽样的再加权处理、面板流失未加权等) 见附录与仓库文档。输出侧的外部效度检验目前只有一项：模拟三年新发孤独梯度与 Wei 等报告的独居/非独居发生率差 (34.0% vs 22.3%) 方向与量级一致 [1]，且该文调整协变量后差异不显著，故仅作描述性互证。关系衰减形态则与 Burt 拟合明确不吻合 (第 7 节)。因此如实表述：**校准的对齐目前在输入侧成立，模型的动力学部分尚未通过任何一项严格的外部效度检验**，这是后续工作最需补足之处。

3.5 预注册与效度门槛

假设 (H1–H4)、主次结局、种子、有效性判据在正式批次启动前写入脚本头部：**主结局** isolation_rate (月度孤立率，定义为当月无任何情感支持接触的老年人比例)；**次结局** avg_loneliness; deep_isolation_rate 仅入敏感性分析，avg_active_ties 仅作描述。**效度门槛**：run 完成 24 月、决策记录非空、焦点老人静默率 $\leq 10\%$ 、LLM 调用错误率 $\leq 5\%$ ；任一不满足即判无效并整体重跑，无效 run 归档留存而非删除。 $n = 3$ 种子不做显著性检验、不宣称稳定排序；H4 为同 run 内“撤出期 – 干预期”的配对对比，标注探索性。

主结局的性质与局限。isolation_rate 是“本月有没有情感接触”的月度快照：任何按月上门的在场型服务（个案管理每月对覆盖对象以 0.8 概率触发一次情感接触）都会在定义层面直接将其清零，因此该指标在干预窗内主要度量“服务是否在场”，图 1 中第 7 月与第 19 月的阶跃即由此产生。孤独感 ℓ 是带稳态回归动力学的连续量（月末向由接触量、关系系数、健康与性格决定的稳态回归一半），更接近真正的结局。预注册将其列为次结局，本文不改预注册地位，但在结果中将两者**并列报告**，并在解释效应量时以孤独感为准、以孤立率为“在场”指标。

4 实验设计

4 条件 (none / casework / timebank / platform) $\times$ 3 种子 $\times$ 24 月，共 12 个有效 run 为目标，最终冻结 11 个：platform seed 2 因焦点老人静默率 11.3% (17/150 agent-月) 超过 10% 门槛判无效 (LLM 错误率 0，静默集中在网关超时步，属基础设施型失

表 1: 分窗口主结局 (孤立率, %; 条件均值)。反弹 = 撤出期 – 干预期, pp。

条件	n	干预期	撤出期	反弹
基线 none	3	29.4	27.2	-2.2
个案 casework	3	7.9	27.5	+19.6
时银 timebank	3	24.7	25.6	+0.8
平台 platform	2	23.5	27.5	+4.0

效)，截止前未能补跑，平台臂以 $n = 2$ 报告；干预窗第 7–18 月，撤出观察第 19–24 月。假设：**H1** 干预期三种干预均降低孤立率，个案管理降幅最大；**H2** 干预期孤独感同向改善；**H3** 三种干预的行为签名可区分 (求助路径、结对、志愿匹配)；**H4** (探索性) 撤出后个案管理反弹大于时间银行——结构性互助更可持续。

5 主结果 (LLM 行为层)

5.1 干预期：个案管理领先

干预期个案管理孤立率 7.9%，对基线 29.4% 相对下降 73%；同 seed 配对差 -21.5pp (配对 $n = 3$)。时间银行 (24.7%) 与平台 (23.5%) 改善有限。孤独感 (并列报告) 方向一致但幅度小得多：个案管理 29.4% 对基线 37.7% (相对下降约 22%，孤立率相对下降 73%)——两指标的幅度差本身说明孤立率主要在测“服务在场”。方向与 Masi 荟萃中认知类干预效应最大的结论一致 [7]，支持 H1/H2。

5.2 H4: 显式机制假设下复现的可持续性分化

撤出后个案管理孤立率反弹 +19.6pp (同 seed 配对差 +21.8pp)，干预期优势几乎清零；时间银行反弹 +0.8pp (图 1、图 2)。规则层 20 种子扫描给出同向形态 (casework 反弹 +7.9 至 +9.5pp、timebank +2.1pp)。

必须说明：这不是涌现发现。两条机制都写在环境规则里——个案管理的情感接触由社工每月来訪直接触发，撤出即消失；时间银行结对撤出后以 post_persist (中点 0.5) 概率延续互动，代码注释明示“延续概率是 H4 的关键机制假设”。LLM 焦点老人与规则老人处在同一环境、共用同一指标定义，规则层与 LLM 层因此不是两条独立证据，早先版本




图 1: 孤立率月度轨迹 (粗线为条件均值, 细线为单种子, 阴影为干预窗第 7–18 月)。个案管理组在第 7 月与第 19 月呈阶跃变化, 对应在场型服务的进入与撤出 (见第 3.5 节对主结局性质的说明)。

“跨层互证”的表述在此撤回。H4 的准确表述是：在显式编码的机制假设下，模拟复现了预期的可持续性分化，并给出了灵敏度范围 (post_persist 0.3–0.7 扫描内方向不变；caseload 4–12 不改变反弹)。它的价值在于把“退出后依赖型支持消失、互惠型关系部分存续”这一实务直觉变成可参数化、可反驳的模型，而非证明它为真。最能检验该假设的补充实验是将 post_persist 置零观察分化是否消失，本文未执行，列为后续工作。

5.3 分层拆解：LLM 层在宏观结果中的权重

表 2 从 replay 中拆出 6 名焦点老人与 14 名规则老人各自的窗口均值。三点观察：(1) 焦点老人的基线孤立率约为规则老人的三倍 (none: 56.9% 对 17.7%)，源于第 3.1 节所述接触生成机制差异——LLM 老人不行动即无接触；(2) LLM 层主导了宏观效应：焦点老人只占 30% 人口，却贡献了基线孤立率的 58%；个案管理对焦点层的配对效应 (干预期 -44.0pp、反弹 +55.1pp) 是规则层 (-11.9pp、+7.5pp) 的三至七倍。因此“生成式智能体模拟”并非装饰——但同时意味着主结果对 LLM 行为特征 (含静默) 高度敏感；(3) 时间银行的“不反弹”主要是规则

表 2: 分层拆解 (窗口均值；孤立率%，孤独感 0–1)。焦点 = 6 名 LLM 老人，规则 = 14 名规则层老人；配对差 = 同 seed 下条件 - none。

条件	焦点孤立率		规则孤立率		孤独感焦点/规则	
	干预期	撤出期	干预期	撤出期	干预期	撤出期
none	56.9	51.8	17.7	16.7	0.56/0.30	0.58/0.33
casework	13.0	63.0	5.8	12.3	0.42/0.24	0.52/0.29
timebank	45.8	52.8	15.7	13.9	0.54/0.29	0.57/0.31
platform	43.1	56.9	15.2	14.9	0.52/0.28	0.53/0.29
配对差 vs none (pp): 干预期 / 反弹						
casework	-44.0 / +55.1		-11.9 / +7.5			
timebank	-11.1 / +12.0		-2.0 / -0.8			
platform	-11.1 / +13.9		-3.3 / +0.9			

层贡献：规则层配对反弹 -0.8pp (post_persist 起作用)，而 LLM 层反弹 +12.0pp，与平台组 (+13.9pp) 相当，仅远小于个案管理 (+55.1pp)。故 LLM 层支持的结论是“个案管理反弹远大于其余两种”，而非“时间银行几乎不反弹”。孤独感在两层均方向一致、幅度平缓。

5.4 行为签名与机制佐证 (H3)

三种干预在焦点老人的行为日志中签名清晰可辨¹：时间银行组求助成功率全场最高 (结对互助起

¹11 个有效 run 的求助请求统计 (tests/behavior_signature.json) : none 3 run 共 249 次、成




图 2：同 seed 配对对比（左：干预期效果；右：撤出反弹，探索性）。

效)；个案管理组求助请求量最大（社工主动触达）但成功率最低之一；基线组与时间银行组请求量相近，平台组均请求量最少且成功率最低。个案管理组“请求最多、成功率最低”值得展开：社工是账本中可达性最高的关系，LLM 老人在有社工在场时更频繁地发起求助（含向社工求助），而社工撤出后老人继续按已习得的模式向不再响应的对象求助，失败请求累积——这是未被规则规定的行为层结果，与“依赖型支持”的实务描述一致，但同样只是 3 种子下的描述性观察。所谓“关系悖论”（撤出后活跃关系系数仍高而孤立率反弹）则需说明其性质：关系账本中社工关系在撤出后按 $\delta = 0.06$ 缓慢衰减、数月内仍计入活跃关系，而孤立率定义只看当月是否有接触——悖论是指标定义的直接后果，不是新的机制证据；它的叙事价值在于提醒“关系存在”与“关系起作用”是两个量。

个体轨迹把该悖论具体化（预注册选例规则：有效 casework run 中撤出前接受过社工探访、且撤出后孤独感反弹最大的焦点老人；探索性证据）。casework_s1 的 18 号老人在撤出时点（第 18 月）孤独感仅 0.19、活跃关系 7 条；至第 24 月关系仅减一条（6 条），孤独感却升至 0.50——网络规模几乎未动，失去的只是激活它的社工节点。时间银行侧无来自有效 run 的对应个案（唯一带显式结对记录的 run 未过静默门槛，个案不入证据），如实说明。这对社工实务的含义是：个案管理应内置向互惠型网络的转介与退出计划。

功 183 (73.5%，均 83.0 次/run)；timebank 247/185 (74.9%，82.3)；casework 412/271 (65.8%，137.3)；platform 2 run 159/94 (59.1%，79.5)。

5.5 两层分歧的如实报告

干预期排序在两层不完全一致：规则层 timebank 优于 platform，LLM 层 platform 略优于 timebank（平台仅 2 个有效 seed，该差异无法与种子噪声区分）。机制上可解释：LLM 层的平台干预引入了新志愿者关系、提升活跃关系系数。我们将其作为“两层差异及其解释”报告而非掩盖——分层设计的价值恰恰在于暴露这类跨层不一致。

6 机制层扩展：时机、剂量与自主闭环

6.1 介入时机的延迟成本

预注册规则层扫描（启动月 {3, 5, 7, 9, 12} × 时长 {6, 12, 18} × 3 条件，20 种子；基线全时程孤立率 15.0%）得到三点发现：

1. **干预即时起效**：干预期内孤立率几乎不随启动时机变化——延迟的全部代价来自未被保护的等待月份，而非“错过关键窗口”；
2. **延迟成本的方向性估计**：启动每推迟一月，两年平均孤立率上升约 +0.15pp (casework) / +0.18pp (timebank)，24 月累计约 3.6 pp（基线 15.0%）；platform 总效应弱故时机不敏感（+0.00pp）。该量级完全由“干预即时起效”这一规则属性决定（表 3），只作规则层机制下的方向性估计；
3. **反弹与剂量无关**：casework 时长从 6 月增至 12 月，撤出反弹不缓解（+7.9 至 +9.5pp）——依赖型支持的反弹是机制属性而非剂量不足。

注意披露：晚启动意味着更短的撤出观察窗（混淆），时长 18 月无撤出窗；规则层绝对水平不与 LLM 批次比较，仅取方向与量级。预防期/预警期/危机期的 LLM 行为层时机对照未完成，属后续工作，此处不将计划写作结果。

6.2 Harness 自主实验闭环

我们演示了受预注册约束的自动化科研回路：LLM 设计师在预注册搜索空间（条件 × 启动月 3–12 × 时长 6–12，目标最小化全时程孤立率，资源帽时长 ≤12）内逐轮提出候选配置，确定性规则层评

表 3: 规定 vs 涌现: 本文各项结果的性质。

结果	性质	来源
孤立率对干预的即时响应 (第 7 月阶跃)	规定	指标定义 + 每月来访触发接触
个案管理撤出后反弹	规定	社工来访停止即无接触
时间银行撤出后 (规则层) 延续	规定	post_persist 参数 (0.5, 扫描 0.3–0.7)
延迟成本按月线性累积	规定	干预即时起效的直接推论
关系数悖论 (关系仍在、激活已失)	规定	衰减慢于按月快照
两层孤立率水平相差三倍	半规定	接触生成机制不同 (3.1 节), 幅度非预设
时间银行 LLM 层仍反弹 +12.0pp	涌现	LLM 老人未按结对关系主动互动
三种干预的求助行为签名	涌现	焦点老人工具调用分布
个案管理组求助最多、成功率最低	涌现	焦点老人行为日志
gpt-6-astra 无干预时更沉默、来访拉动决策	涌现	跨模型对照
行为型静默集中于干预窗内	涌现	失效 run 诊断

估器执行并返回结果, 全部 5 轮审计日志落盘。闭环收敛到 casework start=4 dur=12 (全时程孤立率 7.70%), 与网格最优差异在种子标准差之内——闭环流程成立, 且我们如实报告它复现了网格平台区、并无超越网格的新发现。护栏设计 (LLM 仅提案、评估确定性、空间与轮数预注册、全轮次落盘) 保证该演示不引入选择性报告。此外, 逐 run 的自动分析-反思机制 (analyze.py) 目前实现“发现并标记”, 修改实验配置前需人工审核, 避免中途改变实验设计。

7 科学性核查与诚实偏差报告

7.1 校准对齐与涌现效度

输入分布逐维对齐调查数据 (第 3.4 节)。运行层动态与文献互证: 模拟丧偶冲击方向与 CLHLS 丧偶-孤独动态 (丧偶头几年 OR 3.09) 一致 [11]。表 3 逐条区分本文结果中哪些是环境规则的直接推论、哪些是模拟给出的新信息。这张表是本文对“LLM 模拟是否只是规则回声”这一质疑的正面回答: 宏观结局层面的主要形态多为规定; 涌现内容集中在 LLM 行为层。

7.2 关系衰减的结构化限制

以 Burt 口径实测本模型关系存活曲线 (规则层 50 人 $\times$ 48 月) 发现两点机制层限制: (1) 模型关系流失显著慢于文献 (4 年存活 78.8% 对 Burt 拟合 38.3%); (2) 存在约 46% 的存活率地板——有固定联系频率的子女与高频邻里每月刷新联系时间, 永不进入衰减分支, 因此任何 δ 取值都无法复现 Burt 幂函数的持续下降。我们据此不将关系流失速率作为标定目标, 仅作敏感性维度。引用 Burt 时另有一处更正: 其“家庭以外关系半衰期 2.63 年”为原文漏减常数项的算术错误, 依原文方程重算应为 1.63 年 [5]。深度孤立测度受存活率地板截断, 故仅入敏感性分析。

7.3 建模选择的扫描化处理

三轮独立文献检索 (第三轮经多源聚合接口覆盖 CrossRef/OpenAlex/arXiv) 一致确认: 不存在支持 $\delta = 0.06$ 或 caseload = 8 的权威文献——凑出“完美吻合”数字的检索结果 (本项目在第一轮检索中确曾遇到编造文献与编造数字各一例) 已全部否决存档。因此这两个参数按建模选择处理: δ 扫描 0.06/0.15/0.25 (扫描点依实测存活曲线选取); caseload 在本模型中实际控制高危老人干预覆盖率 (4/8/12 对应 40%/80%/100%), 与现实登记个案量单位不同——纽约市居家老人个案管理的实测平均登记个案量约 75 人/社工且被认为已超载 [12], 中国行业标准仅规定人力配置比而无个案量条款 [13], NASW 明确拒绝统一个案量标准 [14], 故按覆盖率维度扫描。扫描结论: δ 抬升整体水平但不改变干预排序; caseload 干预期内单调、撤出后收敛——覆盖率只影响在场效应, 不影响可持续性。

7.4 失效 run 的根因诊断

按效度门槛 (第 3.5 节) 判无效的 run 全部归档并逐一诊断, 识别出两类失效模式: (1) 基础设施型——LLM 网关错误风暴导致整月决策黑洞 (错误在 trace 中成簇可见), 处置为重跑并调高重试次数 (基础设施参数, 非协议变更); (2) 行为型——LLM 正常思考但不发起环境行动, 集中于干预窗内, 与个案依赖机制一致; 此类无基础设施可修, 按预注册门槛重跑, 若复现则按规则排除并在限制节报告门槛张力 (门槛可能混同“故障静默”与“依赖性合

法不行动”)，另做包含该 run 的敏感性分析，不改门槛。

7.5 模型与推理设定披露

正式批次使用单一模型 (gpt-5.6-sol) 与统一采样设置；思考强度未被运行脚本记录，如实标注“未记录”，后续以小样本对照补充。跨模型稳健性 (gpt-6-astra对照批次，seed 1 的 none 与 casework 两条 run) 列为敏感性检验，不在主结果内，结果见第 7.6 节。

7.6 跨模型敏感性检验

以 gpt-6-astra 替换焦点老人的驱动模型，其余配置 (画像、种子、干预参数、步数) 与主批次 seed 1 完全一致，重跑 none 与 casework 两条 run，比较 casework–none 的干预期孤立率差与撤出反弹方向是否与主模型一致。单 seed、双条件，仅作描述性方向判断，不做显著性声称。结果与静默率对照见表 4。

方向一致。两模型下 casework 相对 none 均呈“干预期压低 + 撤出后反弹更大”：主模型配对差为干预期 −17.1 pp、反弹 +18.8 pp；gpt-6-astra 为干预期 −25.0 pp、反弹 +25.0 pp，且撤出期两臂孤立率回到同一水平 (均为 30.0%)，即 casework 的效果在撤出后完全消失，与前文“注入型节点”解释一致。

行为型静默是模型特征而非偶然故障。gpt-6-astra 的 none 臂两次独立运行 (同一 seed) 静默率分别为 10.7% (16/150 agent-月) 与 11.3% (17/150)，均越过 10% 效度门槛并按规则判无效；两次运行的 LLM 错误率分别为 0.17% 与 0，静默分散在多位老人的多个月份而非集中于网关超时步，与 platform seed 2 的基础设施型失效不同。主批次 11 条 sol run 静默率全部 ≤ 10% (none seed 1 为 4.0%)，而同一模型的 casework 臂静默率仅 2.0%——外部行动者持续来访似乎“拉动”了 astra 焦点老人产出决策，无人干预时该模型更倾向于不给出任何行动。我们将此本身作为稳健性发现报告：(i) 门槛按主模型设定，对更“沉默”的模型可能系统性偏严，局限节对此作出说明；(ii) 表中 astra none 臂的孤立率仅供方向参考，不进入任何主结果；(iii) 第三次重跑被明确放弃，以避免“跑到通过为止”的选择性报告。

表 4: 跨模型敏感性检验 (seed 1, 单 run)。孤立率为窗口均值 (%), 反弹 = 撤出期 − 干预期 (pp); 静默率为焦点老人无决策 agent-月占比 (门槛 10%)。

模型	条件	静默率	干预期	撤出期	反弹
gpt-5.6-sol	none	4.0%	25.8	25.0	−0.8
	casework	8.7%	8.8	26.7	+17.9
gpt-6-astra	none	11.3% [†]	29.6	30.0	+0.4
	casework	2.0%	4.6	30.0	+25.4
配对差 casework–none: sol			−17.1	+1.7	+18.8
配对差 casework–none: astra			−25.0	0.0	+25.0

[†] 超过 10% 门槛判无效；首次运行行为 10.7% (16/150)，同样越线，行为指标仅供方向参考。

对 LLM 社会模拟效度门槛设计的一般含义。这一发现超出本案例：(a) “不行动”在 LLM 智能体中既可能是故障、也可能是模型的默认行为倾向，且该倾向随模型而异、随环境中是否存在主动行动者而变——门槛若按单一模型标定，跨模型比较就会系统性偏向“更爱行动”的模型；(b) 外部行动者的存在会拉动 LLM 产出决策，意味着干预臂与对照臂的静默率天然不对称，以静默率为门槛会对对照臂更严，进而可能高估干预效应；(c) 可行的改进是把门槛写成相对量 (干预臂与对照臂静默率之差) 或在预注册中为每个模型单独标定基线静默率。我们建议后续 LLM 社会模拟工作把“无干预基线静默率”作为模型选型的必报指标。

8 真实成本核算

多智能体 LLM 实验的成本报告必须计入被质量门槛淘汰的 run。本项目累计 LLM 调用 45,901 次 (trace 实测，含归档失效 run)，估算总成本 \$1056: 主批次有效 run \$529、无效沉没 \$409 (占主批次 44%)，另有跨模型对比臂 \$118 (第 7.6 节)。token 用量为文档化假设 (trace 未记录逐调用用量)、单价按公开定价，口径随数据文件公开。分层设计的意义在此具体化：规则层扫描 (20 种子 × 45 配置) 与 harness 闭环全部零 API 成本；若以 LLM 层完成同等扫描，成本将超出主批次一个数量级。

9 讨论与政策含义

(一) 轮候时间是可被建模的干预设计变量。规则层机制下干预即时起效、延迟成本按月线性累积 (约 +0.15pp/月)。这只是方向性估计：它成立的前

提是干预一到位即产生接触，真实服务的启动滞后与覆盖爬坡会改变量级。

(二) 个案管理需要内置退出计划。干预期效果最强与撤出后反弹最大是同一机制的两面：社工是被注入的活跃节点。反弹不随剂量缓解，提示退出设计（逐步减量、向互惠网络转介）应作为个案管理的标准组件而非可选项——这与“关系仍在、激活已失”的叙事一致（其性质见第 5 节）。

(三) 结构性互助的可持续性有待检验假设而非结论。时间银行的撤出后延续在规则层由 `post_persist` 规定，在 LLM 层并未自发出现（焦点老人反弹 +12.0pp）。因此“个案管理开路、时间银行接续”应作为后续实验假设提出，并以 `post_persist = 0` 对照检验其是否依赖该参数。

(四) 弱干预谈时机无意义。平台类干预总效应弱，时机不敏感——先保证强度，再优化时机。

以上均为模型机制结论，用于生成可检验的政策假设，不宣称真实人群的因果效应。

10 局限与伦理

局限。 (1) $n = 3$ 种子（平台臂 $n = 2$ ）只支持描述性对比与方向判断，不支持显著性与稳定排序；(2) 关系衰减机制存在 46% 存活率地板，慢于文献实证形态；(3) LLM 焦点老人的行为效度依赖模型本身，行为型静默与真实老人的“合法不行动”难以区分，且 10% 静默门槛按主模型 `gpt-5.6-sol` 设定，对更倾向“不行动”的模型（`gpt-6-astra none` 臂两次为 10.7–11.3%）可能系统性偏严，见第 7.6 节；(4) 校准数据存在口径差（调查波次、独居子样本 vs 全体）；(5) 撤出观察窗仅 6 个月；(7) 主结局 `isolation_rate` 为月度接触快照，被在场型服务直接命中，效应量应以孤独感为准；(8) 宏观结果的一半以上由 6 名 LLM 老人贡献，主结果对 LLM 行为特征高度敏感；(6) Ristolainen RCT 的亚组效应存在基线不可比问题 [9]，个案管理参数依据以 Masi 荟萃为主。

伦理。 全部智能体为模拟实体，不涉及真实个人；调查数据仅使用公开微观数据的聚合分布；LLM 生成的“老人理由”是机制探针而非真实老人话语，论文避免将其拟人化引用。模拟结论若被直接当作资源分配依据存在误用风险，故本文反复强调其假设生成属性。

11 结论

本文的主要产出是一套面向 LLM 社会模拟的科学性纪律，并以独居老人社会支持干预为案例完整演示：预注册与效度门槛、真实数据锚定与偏差如实报告、失效根因分类、含沉没成本的成本透明、受护栏约束的自主实验闭环，以及“规定 vs 涌现”的逐条对照。案例结果中，干预期个案管理领先与撤出后可持续性分化是在显式机制假设下复现的预期形态；分层拆解表明宏观结果由 LLM 层主导、时间银行的延续主要来自规则层。真正来自模拟的新信息在行为层：可区分的求助签名、个案管理组的高请求低成功、以及 `gpt-6-astra` 在无干预时更沉默且被来访拉动——后者对整个领域的效度门槛设计具有一般含义。我们把这些边界画清楚，正是为了让后续工作（`post_persist` 置零对照、多模型基线静默率标定、LLM 层时机对照）有明确的靶子。全部数字由脚本自动生成，欢迎按附录复现。

参考文献

- [1] Kai Wei, Yuanyuan Liu, Jia Yang, Nannan Gu, Xinyi Cao, Xudong Zhao, Lijuan Jiang, and Chunbo Li. Living arrangement modifies the associations of loneliness with adverse health outcomes in older adults: Evidence from the CLHLS. *BMC Geriatrics*, 22:59, 2022. doi: 10.1186/s12877-021-02742-5.
- [2] Shiyu Lu, Cheryl Chui, Terry Lum, Tianyin Liu, Gloria Wong, and Wai Chan. Promoting late-life volunteering with timebanking: A quasi-experimental mixed-methods study in Hong Kong. *Innovation in Aging*, 8(7):igae056, 2024. doi: 10.1093/geroni/igae056.
- [3] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. *Proceedings of UIST '23*, 2023. doi: 10.1145/3586183.3606763.
- [4] Robert L. Kahn and Toni C. Antonucci. Convoys over the life course: Attachment, roles, and social support. *Life-Span Development and Behavior*, 3:253–286, 1980.
- [5] Ronald S. Burt. Decay functions. *Social Networks*, 22(1):1–28, 2000. doi: 10.1016/S0378-8733(99)00015-5.
- [6] Karen E. Klein Ikkink and Theo G. van Tilburg. Broken ties: Reciprocity and other factors affecting the termination of older adults' relationships. *So-*

cial Networks, 21(2):131–146, 1999. doi: 10.1016/S0378-8733(99)00005-2.

- [7] Christopher M. Masi, Hsi-Yuan Chen, Louise C. Hawkey, and John T. Cacioppo. A meta-analysis of interventions to reduce loneliness. *Personality and Social Psychology Review*, 15(3):219–266, 2011. doi: 10.1177/1088868310377394.
- [8] Peter Hoang, James A. King, Sara Moore, Kim Moore, Krista Reich, Harman Sidhu, Chin Vern Tan, Colin Whaley, and Jacqueline McMillan. Interventions associated with reduced loneliness and social isolation in older adults: A systematic review and meta-analysis. *JAMA Network Open*, 5(10):e2236676, 2022. doi: 10.1001/jamanetworkopen.2022.36676.
- [9] Hanna Ristolainen, Sirpa Kannasojä, Elisa Tiilikainen, Mari Hakala, Kati Närhi, and Sari Rissanen. Effects of ‘participatory group-based care management’ on wellbeing of older people living alone: A randomized controlled trial. *Archives of Gerontology and Geriatrics*, 89:104095, 2020. doi: 10.1016/j.archger.2020.104095.
- [10] Elin Taube, Jimmie Kristensson, Patrik Midlöv, and Ulf Jakobsson. The use of case management for community-dwelling older people: The effects on loneliness, symptoms of depression and life satisfaction in a randomised controlled trial. *Scandinavian Journal of Caring Sciences*, 32(2):889–901, 2018. doi: 10.1111/scs.12520.
- [11] Fang Yang and Danan Gu. Widowhood, widowhood duration, and loneliness among older adults in China. *Social Science & Medicine*, 283:114179, 2021. doi: 10.1016/j.socscimed.2021.114179.
- [12] Manoj Pardasani. Case management for home-bound older adults in New York City: What is an appropriate caseload size? *Educational Gerontology*, 44(11):712–723, 2018. doi: 10.1080/03601277.2018.1555205.
- [13] Ministry of Civil Affairs of the People’s Republic of China. Guideline for elderly social work services (MZ/T 064–2016). Technical report, National Technical Committee on Social Work Standardization (SAC/TC 534), 2016. Recommended industry standard, in force.
- [14] National Association of Social Workers. NASW standards for social work case management. Technical report, NASW, 2013. Standard 11: Workload Sustainability.

A 可复现性清单

- 代码与数据: AgentSociety2仓库
examples/v2/elder_support/; 环境模块
custom/envs/elder_support_env.py。
- 正式批次: run_batch.sh 24 1 2 3 (断点自动续跑; 效度门槛与归档逻辑内置)。
- 分析与图表: tools/compare_conditions.py
→ comparison.json;
tools/make_figures.py (每图配同名 CSV);
tools/gen_paper_numbers.py (本文全部数字的唯一来源)。
- 机制扫描与闭环: tests/scan_timing.py、
tools/harness_loop.py (预注册头部 + 逐轮 JSONL 审计日志)。
- 成本与诊断: tools/cost_report.py、
tests/silence_diagnosis.json。
- 校准文档: data_pipeline/out/ 下
calibration_targets.md 与
references_verified.md (含已否决条目与核实方法)。
- 实时面板:
<https://agentsociety.shangdian.me> (批次进度、结论卡片、机制证据、成本与失效诊断)。

B 效度门槛判定细则

run有效当且仅当: DONE 标志存在; 月度指标 0–24 完整; 决策记录非空; 6 名焦点老人合计静默率 $\leq 10\%$ (严格大于 0.10 判无效); LLM 调用错误率 $\leq 5\%$ 。判无效的 run 以时间戳目录归档 (*.invalid-<timestamp>), 保留全部 trace 与决策日志供诊断, 不删除。